

大学連携授業（第一高校） -2

このマニュアルは <https://wasuke.github.io/kyouzai001/> から参照できます。


HTMLの作成

まず、今日の作業用フォルダを作成します。デスクトップで右クリックし、表示されるメニューから「新規作成」を選択し、「フォルダー」をクリックします。新しいフォルダーが作成されるので、名前を入力してEnterキーを押します。今日の作業用フォルダーは「daiichi02」にしておきましょう。

次に、VSCodeを起動し、上部メニューから「ファイル」を選択し、「フォルダーを開く」を選択します。すると、ファイル選択画面が出てきますので、「デスクトップ」の「daiichi02」を開いてください。すると、「このフォルダー内のファイルの作成者を信頼しますか？」というダイアログが現れるので、「はい、作成者を信頼します」を選択します。

以下のようなウィンドウが現れれば、準備完了です。新しいファイルをクリックして、voice2.htmlと名前をつけて、空ファイルを作ります。


コード配布ページのコード2をコピーし、中央部のテキストエディターに貼り付けて、セーブ(Ctrl+s)してください。これで、コードの準備完了です。



コードの実行

VSCodeのエクスプローラから、実行したいコード（この場合はvoice2.html）を右クリックし、一番上にある「Open with...」という選択肢を選びます。この選択肢が出ていない場合は、前回のLive Serverのインストールが済んでいません。確認してください。

Open With...を選択すると、Webブラウザが起動して、質素なメニューが登場します。



マイクで話した言葉を文字にする

今回は、Webブラウザに用意されている Web Speech API という機能を使って、マイクに向かって話した言葉を文字に変換します。スマートフォンで音声入力を使ったことがある人もいると思います。今回作る仕組みも基本的には同じです。

処理の流れは、

マイクに向かって話す

↓

ブラウザが音声を受け取る

↓

音声認識を行う

↓

認識された言葉を文字として表示する

というものです。

今回のプログラムでは、「録音開始」ボタンを押すとマイクからの入力が始まります。話した内容が認識されると、その結果が画面上のテキスト欄に表示されます。

Web Speech APIとは

Web Speech API は、Webブラウザから音声認識などの機能を利用するための仕組みです。今回のコードでは、

```
const SpeechRecognition =  
window.SpeechRecognition ||  
window.webkitSpeechRecognition;
```

という部分で、ブラウザが持っている音声認識機能呼び出しています。

そのあと、

```
recognition.lang = "ja-JP";
```

と設定することで、「これから入力される音声は日本語です」と指定しています。人間でも、何語を聞いているのか分かっていた方が言葉を聞き取りやすくなります。コンピュータにも、あらかじめ日本語を認識させることを伝えています。

「録音開始」を押すと何が起きるのか

「録音開始」ボタンをクリックすると、

```
recognition.start();
```

が実行されます。

これによってブラウザの音声認識が開始されます。初めて実行したときには、ブラウザから「このWebページにマイクの使用を許可しますか?」といった確認が表示されます。「許可」を選択してください。マイクが使用できる状態になると、画面には

状態：録音中

と表示されます。

話し終わると、音声認識の結果がプログラムに返されます。

認識された文字を取り出す

音声認識が終わると、

```
recognition.onresult
```

という部分が動きます。ここには、ブラウザが認識した結果が入っています。例えば、「今日はいいい天気ですね」と話した場合、音声認識が成功すると、

今日はいいい天気ですね

という文字列が返されます。プログラムでは、その文字列を

```
const transcript = result.transcript;
```

で取り出しています。transcript は、「書き起こされた文章」という意味です。

取り出した文字列を、

```
textArea.value = transcript;
```

によって、Webページ上のテキスト欄に表示しています。つまり、この部分までで、

音声 → 文字列

という変換が完成しています。

音声認識は何をしているのか

私たちがマイクに向かって話すと、コンピュータには最初から文字が届くわけではありません。最初が届くのは、声の大きさが時間とともに変化する「音のデータ」です。音声認識では、この音の特徴を調べ、「この音は『きょ』に近い」「この後には『う』が続いていそうだ」「文章としては『今日は』という並びが自然だ」といった情報を組み合わせながら、最終的な文字列を決めています。

人間が会話を聞くとともに、音だけを聞いているわけではありません。例えば、「今日はいい○○ですね」と聞こえたとき、周囲の状況や文章の流れから「天気」という言葉を予想することがあります。音声認識でも、音の特徴だけでなく、言葉の並び方などを利用して認識結果を決めています。

最近「AI」というと、ChatGPTのように文章や画像を作る生成AIを思い浮かべることが多くなりました。しかし、AIは生成AIだけではありません。今回使っている音声認識もAIを利用した技術です。

人間がマイクに向かって話すと、コンピュータに入力されるのは「文字」ではなく「音の波形」です。音声認識AIは、その音の特徴を調べて、

「この音は『あ』らしい」

「この音の並びなら『今日は』という言葉らしい」

「この文章の流れなら、この単語が自然だ」

というように候補を推定し、最終的に文字列へ変換します。

ChatGPTのような生成AIは、「入力をもとに新しい文章などを作るAI」です。一方、今回使う音声認識AIは、入力された音声は何を意味しているのかを認識するAIです。AIには、生成するものだけでなく、

- ・ 画像を見て何が写っているか判断する
- ・ 音声を聞いて文字に変換する
- ・ 迷惑メールかどうか判定する
- ・ 顔や物体を認識する

といった「認識・分類・予測」を行うものもあります。

ここまでで完成したもの

ここまでのプログラムでは、

人が話す

↓



という処理ができるようになりました。ここで重要なのは、音声は文字列に変わったという点です。コンピュータにとって文字列は扱いやすいデータなので、この先は、この文字を保存したり、検索したり、AIに送ったり、別の声で読み上げたりできます。

来週は、この認識された文字列を VOICEVOX に渡して、別の声でしゃべらせます。